UIDE
Powered by
Arizona State University®

Proyecto Integrador

Diseño e Implementación de un Pipeline de Datos para el Entrenamiento de Modelos de Aprendizaje Automático

Sexto Semestre

Contenido

Introducción 5
Contexto del proyecto 5
Objetivos 7
Objetivo general 7
Objetivos específicos 7
Alcance 8
Requerimientos 9
Requerimientos funcionales 10
1. Desarrollo de Proyectos de Sistemas de Información 10
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 10
3. Prácticas y Herramientas de Big Data 10
4. Machine Learning 11
5. Ciberseguridad 11
6. Integración del Proyecto 11
Requerimientos no funcionales 12
1. Rendimiento 12
2. Disponibilidad 12
3. Escalabilidad 12
4. Seguridad 12
5. Mantenibilidad 13
6. Usabilidad 13
7. Confiabilidad 13
Caso de uso 13
Desarrollo de Proyectos de Sistemas de Información 14
Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 15
Prácticas y Herramientas de Big Data 16

Machine Learning 17
Ciberseguridad 18
Diseño de arquitectura 19
Desarrollo 19
Tecnologías 19
Estructura del proyecto 19
1. Desarrollo de Proyectos de Sistemas de Información 20
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 20
3. Prácticas y Herramientas de Big Data 20
4. Machine Learning 20
5. Ciberseguridad 21
Desarrollo de funcionalidades 21
1. Desarrollo de Proyectos de Sistemas de Información 21
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 21
3. Prácticas y Herramientas de Big Data 22
4. Machine Learning 22
5. Ciberseguridad 22
Resultados 23
Casos de prueba 23
1. Desarrollo de proyectos de sistemas de información 23
2. Tendencias en tecnologías emergentes y modelos de negocios digitales 23
3. Prácticas y herramientas de Big Data 23
4. Machine Learning 23
5. Ciberseguridad 23
Resultados de funcionalidades 23
1. Desarrollo de Proyectos de Sistemas de Información 23
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 24

3. Prácticas y Herramientas de Big Data 24
4. Machine Learning 24
5. Ciberseguridad 24
Capturas de funcionalidades 25
1. Desarrollo de Proyectos de Sistemas de Información 25
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales 25
3. Prácticas y Herramientas de Big Data 25
4. Machine Learning 25
5. Ciberseguridad 26
Rúbricas de calificación 26
1. Desarrollo de proyectos de sistemas de información 26
2. Tendencias en tecnologías emergentes y modelos de negocios digitales 27
3. Prácticas y herramientas de Big Data 29
4. Machine Learning 30
5. Ciberseguridad 31
Conclusiones 31

Introducción

Contexto del proyecto

En la actualidad, las organizaciones generan y consumen grandes volúmenes de información provenientes de diversas fuentes, como plataformas web, redes sociales, sensores, servicios en la nube y APIs públicas o privadas. La capacidad para recolectar, procesar, analizar y proteger estos datos se ha convertido en un factor estratégico para la toma de decisiones, permitiendo identificar patrones de comportamiento, optimizar procesos y desarrollar soluciones inteligentes que aporten valor al negocio. De este modo, las empresas requieren profesionales capaces de integrar tecnologías de análisis de datos, aprendizaje automático, gestión de proyectos y ciberseguridad dentro de un mismo ecosistema tecnológico.

Con el propósito de atender esta necesidad, el presente proyecto integrador propone el diseño e implementación de un Pipeline de Datos, articulando los conocimientos adquiridos en las asignaturas de Desarrollo de Proyectos de Sistemas de Información, Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales, Prácticas y Herramientas de Big Data, Machine Learning y Ciberseguridad, permitiendo desarrollar una solución tecnológica desde la planificación del proyecto hasta la generación de modelos predictivos y la evaluación de la seguridad de los servicios utilizados.

Desde la asignatura de Desarrollo de Proyectos de Sistemas de Información, los estudiantes deberán planificar, organizar, ejecutar y controlar el desarrollo del proyecto utilizando metodologías ágiles, estableciendo un cronograma de trabajo, definición de requerimientos, gestión de riesgos, seguimiento de actividades y documentación de los resultados obtenidos. Además, se deberá realizar una comparación entre la planificación inicial y la ejecución real del proyecto, analizando las desviaciones presentadas y proponiendo acciones de mejora que permitan fortalecer la gestión de proyectos tecnológicos en escenarios reales.

Desde la asignatura de Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales, el proyecto incorporará el análisis del impacto de las tecnologías utilizadas dentro del contexto empresarial, identificando oportunidades de innovación mediante el uso de inteligencia artificial, analítica de datos y servicios en la nube. Los estudiantes evaluarán el modelo de negocio asociado a la solución desarrollada, considerando aspectos relacionados con la transformación digital, la generación de valor, la escalabilidad, la sostenibilidad tecnológica y la incorporación de tecnologías emergentes como elemento diferenciador para organizaciones basadas en datos.

El procesamiento y análisis de grandes volúmenes de información será desarrollado desde la asignatura de Prácticas y Herramientas de Big Data, donde los estudiantes implementarán un pipeline de adquisición, limpieza, transformación y almacenamiento de datos utilizando herramientas de procesamiento distribuido ejecutadas sobre Google Colab. La información será obtenida mediante el consumo de APIs públicas o privadas, permitiendo construir conjuntos de datos estructurados que posteriormente servirán como base para el análisis exploratorio y el entrenamiento de modelos predictivos. Durante este proceso se aplicarán técnicas de preparación de datos, integración de múltiples fuentes de información y optimización de los flujos de procesamiento para garantizar la calidad y disponibilidad de los datos.

Como parte de la asignatura de Machine Learning, los estudiantes desarrollarán modelos de aprendizaje automático que permitan obtener conocimiento a partir de los datos procesados. Para ello, realizarán el análisis exploratorio de la información, selección y transformación de variables, entrenamiento de modelos supervisados o no supervisados, evaluación mediante métricas de desempeño y comparación entre diferentes algoritmos para seleccionar la alternativa más adecuada al problema planteado. Finalmente, los modelos deberán integrarse dentro del pipeline de datos para generar predicciones o clasificaciones que aporten información relevante para la toma de decisiones.

Desde la perspectiva de Ciberseguridad, el proyecto deberá evaluar la seguridad del ecosistema tecnológico implementado, realizando un análisis de vulnerabilidades sobre las APIs consumidas y los servicios utilizados durante el desarrollo de la solución. Los estudiantes identificarán riesgos relacionados con la autenticación, autorización, protección de datos, exposición de información, configuración de servicios y comunicaciones seguras, proponiendo e implementando mecanismos de mitigación basados en buenas prácticas de seguridad. Asimismo, se analizarán aspectos relacionados con la confidencialidad, integridad y disponibilidad de la información, considerando estándares y recomendaciones aplicables al desarrollo de aplicaciones orientadas al consumo de servicios web.

Como resultado, cada grupo desarrollará un ecosistema integral de análisis de datos que abarcará desde la planificación y gestión del proyecto hasta la extracción masiva de información, el procesamiento de datos mediante herramientas de Big Data, el entrenamiento de modelos de Machine Learning y la evaluación de la seguridad de los servicios involucrados. La solución permitirá demostrar la integración de competencias técnicas, organizacionales y analíticas adquiridas durante el semestre, simulando un escenario real de desarrollo de plataformas inteligentes basadas en datos que respondan a las necesidades actuales de las organizaciones en su proceso de transformación digital.

Objetivos

Objetivo general

Diseñar, implementar y validar un Pipeline de datos que integre la gestión de proyectos de sistemas de información, el procesamiento de grandes volúmenes de datos mediante arquitecturas y herramientas de Big Data, el desarrollo de modelos predictivos de Machine Learning, el análisis de tendencias tecnológicas y modelos de negocios digitales, y la evaluación de la seguridad en el consumo de APIs y servicios web, aplicando estándares profesionales de documentación, ética y buenas prácticas en el desarrollo de soluciones basadas en datos.

Objetivos específicos

1. Desarrollo de proyectos de sistemas de información

Planificar, gestionar y documentar el desarrollo del proyecto utilizando metodologías ágiles, definiendo el Product Backlog, los Sprints, el cronograma de trabajo y realizando el seguimiento de la ejecución mediante una herramienta de gestión de proyectos, documentando además la gobernanza e infraestructura tecnológica utilizada durante el desarrollo.

2. Tendencias en tecnologías emergentes y modelos de negocios digitales

Analizar la aplicación de tecnologías emergentes y su impacto dentro del modelo de negocio propuesto, evaluando cómo el uso de Big Data, Machine Learning y servicios en la nube generan ventajas competitivas, promueven la transformación digital y aportan valor a organizaciones orientadas al uso estratégico de los datos.

3. Prácticas y herramientas de Big Data

Diseñar e implementar un pipeline de procesamiento de datos que permita la extracción de información desde APIs, la limpieza, transformación e integración de datos mediante procesos ETL ejecutados en Google Colab.

4. Machine Learning

Desarrollar, entrenar y evaluar modelos de aprendizaje automático utilizando los datos procesados, comparando métricas de desempeño, generando visualizaciones y justificando técnicamente la selección de algoritmos y componentes utilizados para la construcción del modelo predictivo.

5. Ciberseguridad

Analizar las vulnerabilidades presentes en las APIs, herramientas de conexión e infraestructura tecnológica empleada en el proyecto, proponiendo mecanismos de mitigación que garanticen la

confidencialidad, integridad y disponibilidad de la información durante el procesamiento e intercambio de datos.

6. Integración del Proyecto

Integrar la gestión del proyecto, el pipeline de Big Data, los modelos de Machine Learning, el análisis de tecnologías emergentes y los mecanismos de ciberseguridad en una única solución tecnológica funcional, validando su desempeño mediante pruebas de procesamiento, predicción, seguridad e integración de todos los componentes del sistema.

Alcance

El presente proyecto comprende el diseño, implementación, integración y validación de un Pipeline de Datos que permita la adquisición, procesamiento, análisis y explotación de grandes volúmenes de datos, integrando la gestión del proyecto, herramientas de Big Data, modelos de Machine Learning, el análisis de tecnologías emergentes y la evaluación de la seguridad en el consumo de APIs y servicios web.

La solución contempla la planificación y gestión integral del proyecto utilizando metodologías ágiles, mediante la definición del Product Backlog, planificación de Sprints, elaboración del cronograma inicial y seguimiento de la ejecución real utilizando una herramienta de gestión de proyectos de libre elección, como Jira, Trello o Azure DevOps. Además, se documentará la infraestructura tecnológica empleada durante el desarrollo, así como los procesos de gobernanza asociados a los recursos de TI utilizados por el equipo.

El componente de procesamiento de datos incluirá la implementación de un pipeline de extracción, transformación y carga (ETL) utilizando Google Colab como entorno principal de desarrollo. Los estudiantes deberán consumir información desde al menos una API abierta, realizar procesos de limpieza, integración y transformación de los datos, generando un conjunto de información estructurada que servirá como base para las etapas posteriores de análisis y modelamiento. Asimismo, se evaluará el rendimiento del procesamiento mediante la implementación y comparación de al menos tres alternativas o modelos de procesamiento de datos.

En el componente de análisis predictivo, se desarrollarán modelos de Machine Learning utilizando los datos previamente procesados. El proyecto incluirá la preparación del conjunto de datos, entrenamiento, validación y comparación de modelos mediante métricas de desempeño apropiadas al problema planteado. Los resultados deberán presentarse mediante visualizaciones y dashboards que faciliten la interpretación del comportamiento de los modelos, complementándose con una

justificación técnica sobre la selección de algoritmos, técnicas de preprocesamiento y componentes utilizados durante el desarrollo.

Como parte del componente de Ciberseguridad, se realizará un análisis de las vulnerabilidades presentes en las APIs consumidas, las herramientas utilizadas para el intercambio de información y la infraestructura tecnológica empleada durante el proyecto. Los estudiantes deberán identificar posibles amenazas relacionadas con la autenticación, autorización, exposición de datos, transmisión de información y configuración de servicios, proponiendo mecanismos de mitigación orientados a preservar la confidencialidad, integridad y disponibilidad de la información durante todo el ciclo de procesamiento de datos.

Adicionalmente, el proyecto incorporará un análisis del potencial de las tecnologías emergentes y su aplicación dentro de modelos de negocios digitales, evaluando cómo la integración de Big Data, Machine Learning y servicios en la nube contribuye a la transformación digital, la generación de valor y la innovación en organizaciones orientadas al uso estratégico de los datos.

La validación del proyecto incluirá la verificación del funcionamiento del pipeline de extracción y procesamiento de datos, la correcta integración entre las diferentes etapas del flujo de trabajo, la evaluación del desempeño de los modelos de Machine Learning, la presentación de resultados mediante dashboards y el análisis de seguridad realizado sobre las APIs y la infraestructura utilizada, demostrando la integración de los conocimientos adquiridos en las asignaturas de Desarrollo de Proyectos de Sistemas de Información, Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales, Prácticas y Herramientas de Big Data, Machine Learning y Ciberseguridad.

El proyecto no contempla el desarrollo de sistemas de procesamiento distribuido sobre clústeres físicos, la implementación de plataformas empresariales de Big Data como Hadoop o Spark en ambientes productivos, el despliegue de modelos de Machine Learning en producción, la automatización mediante procesos MLOps, ni la realización de pruebas avanzadas de penetración o auditorías de seguridad sobre sistemas reales, salvo que estas funcionalidades sean incorporadas como mejoras adicionales por iniciativa del grupo de trabajo.

Requerimientos

La solución propuesta deberá satisfacer un conjunto de requerimientos funcionales y no funcionales que garanticen la correcta integración entre la gestión del proyecto, el procesamiento de grandes volúmenes de datos, el desarrollo de modelos de aprendizaje automático, el análisis de tecnologías emergentes y la evaluación de la seguridad en el consumo de APIs. Estos requerimientos servirán

como base para el diseño, implementación y validación del proyecto, permitiendo que cada asignatura contribuya al desarrollo de una solución integral de inteligencia de datos.

Requerimientos funcionales

Los requerimientos funcionales describen las funcionalidades que deberá cumplir la solución tecnológica, organizadas de acuerdo con las competencias de cada asignatura participante.

1. Desarrollo de Proyectos de Sistemas de Información
    - Definir el Product Backlog con las historias de usuario necesarias para el desarrollo del proyecto.
    - Planificar y organizar el desarrollo mediante Sprints utilizando una metodología ágil.
    - Elaborar un cronograma inicial de actividades con los entregables correspondientes.
    - Registrar la ejecución real del proyecto utilizando una herramienta de gestión de proyectos de libre elección (Jira, Trello, Azure DevOps o similar).
    - Documentar el avance del proyecto y comparar la planificación inicial con la ejecución real.
    - Documentar la infraestructura tecnológica utilizada durante el desarrollo del proyecto.
    - Definir mecanismos básicos de gobernanza para la administración de los recursos tecnológicos utilizados.
    - Mantener un repositorio Git organizado y actualizado durante todo el desarrollo del proyecto.
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales
    - Analizar la aplicación de tecnologías emergentes dentro del proyecto desarrollado.
    - Identificar oportunidades de innovación mediante el uso de Big Data, Machine Learning y servicios en la nube.
    - Evaluar el modelo de negocio asociado a la solución tecnológica propuesta.
    - Analizar el impacto de la transformación digital en el contexto del proyecto.
    - Justificar el valor agregado generado por la utilización de tecnologías emergentes.
    - Documentar las ventajas competitivas obtenidas mediante la solución implementada.
3. Prácticas y Herramientas de Big Data
    - Consumir información desde al menos una API abierta.
    - Implementar un proceso de extracción, transformación y carga (ETL) utilizando Google Colab.
    - Realizar procesos de limpieza y preparación de los datos obtenidos.

- Integrar diferentes conjuntos de datos cuando el problema lo requiera.
- Almacenar la información procesada para su posterior análisis.
- Implementar y comparar al menos tres alternativas o modelos de procesamiento de datos.
- Documentar el flujo completo del pipeline de procesamiento de datos.
- Garantizar la calidad e integridad de los datos durante todas las etapas del procesamiento.

4. Machine Learning
   - Preparar los datos para el entrenamiento de modelos de Machine Learning.
   - Implementar al menos tres modelos de aprendizaje automático para resolver el problema planteado.
   - Comparar el desempeño de los modelos utilizando métricas apropiadas.
   - Seleccionar el modelo con mejor rendimiento mediante una justificación técnica.
   - Generar visualizaciones que permitan interpretar los resultados obtenidos.
   - Construir dashboards que presenten las métricas y resultados del modelo seleccionado.
   - Documentar el proceso de entrenamiento, validación y evaluación de los modelos desarrollados.
   - Justificar técnicamente la selección de algoritmos, parámetros y herramientas utilizadas.
5. Ciberseguridad
   - Analizar las herramientas utilizadas para el consumo de APIs.
   - Identificar vulnerabilidades presentes en las APIs consumidas.
   - Analizar los riesgos asociados al intercambio de información entre servicios.
   - Evaluar la seguridad de la infraestructura tecnológica utilizada durante el proyecto.
   - Identificar amenazas relacionadas con autenticación, autorización y exposición de datos.
   - Proponer mecanismos de mitigación para reducir las vulnerabilidades identificadas.
   - Aplicar recomendaciones orientadas a garantizar la confidencialidad, integridad y disponibilidad de la información.
   - Documentar el análisis de riesgos y las medidas de seguridad propuestas.
6. Integración del Proyecto
   - Integrar la planificación del proyecto con la ejecución técnica del pipeline de datos.
   - Implementar un pipeline completo de extracción, procesamiento y almacenamiento de datos.
   - Integrar los datos procesados con los modelos de Machine Learning desarrollados.

- Presentar los resultados mediante dashboards y visualizaciones que faciliten la toma de decisiones.
- Incorporar el análisis de tecnologías emergentes y modelos de negocio como parte de la propuesta de valor del proyecto.
- Evaluar la seguridad del ecosistema tecnológico y documentar las vulnerabilidades encontradas junto con sus mecanismos de mitigación.
- Validar el funcionamiento integral de todos los componentes desarrollados.
- Documentar el diseño, implementación, pruebas y resultados obtenidos durante el desarrollo del proyecto.

Requerimientos no funcionales

1. Rendimiento
   - Garantizar tiempos adecuados para la extracción y procesamiento de datos desde las APIs.
   - Optimizar el procesamiento de información utilizando herramientas compatibles con Google Colab.
   - Mantener un desempeño eficiente durante el entrenamiento y evaluación de los modelos de Machine Learning.
2. Disponibilidad
   - Garantizar la disponibilidad de las APIs y fuentes de datos durante las pruebas del proyecto.
   - Mantener operativos los componentes del pipeline durante el procesamiento de la información.
   - Asegurar el acceso continuo a los recursos tecnológicos utilizados durante el desarrollo.
3. Escalabilidad
   - Permitir la incorporación de nuevas fuentes de datos sin modificar la arquitectura principal del pipeline.
   - Facilitar la integración de nuevos modelos de Machine Learning y procesos de análisis.
   - Permitir la reutilización del pipeline para diferentes conjuntos de datos y problemas de análisis.
4. Seguridad
   - Proteger la información obtenida durante el consumo de APIs.
   - Garantizar la confidencialidad, integridad y disponibilidad de los datos procesados.

- Identificar y mitigar vulnerabilidades presentes en las herramientas, APIs e infraestructura utilizada.
- Aplicar buenas prácticas de seguridad durante todo el ciclo de vida del proyecto.

5. Mantenibilidad
   - Mantener una estructura organizada del código fuente y de la documentación técnica.
   - Documentar cada etapa del pipeline de procesamiento de datos.
   - Gestionar el proyecto mediante un repositorio Git correctamente organizado y actualizado.
   - Documentar la planificación, ejecución y resultados obtenidos durante el desarrollo.
6. Usabilidad
   - Presentar dashboards y visualizaciones que faciliten la interpretación de los resultados.
   - Organizar la documentación técnica de manera clara y estructurada.
   - Facilitar la comprensión del flujo completo del pipeline de datos.
7. Confiabilidad
   - Garantizar la consistencia de los datos durante las etapas de extracción, transformación y análisis.
   - Verificar la reproducibilidad de los experimentos de Machine Learning.
   - Validar el correcto funcionamiento e integración entre la gestión del proyecto, el procesamiento de datos, los modelos predictivos y el análisis de seguridad.

Caso de uso

Una organización requiere implementar un Pipeline de Datos que permita extraer información desde APIs, procesarla mediante herramientas de Big Data y generar modelos de aprendizaje automático para apoyar la toma de decisiones. La solución se desarrollará utilizando Google Colab, integrando procesos ETL, entrenamiento de modelos predictivos y un análisis de ciberseguridad sobre las APIs y la infraestructura utilizada. El proyecto será gestionado mediante metodologías ágiles, documentando cada una de sus etapas y los resultados obtenidos.

Desarrollo de Proyectos de Sistemas de Información

Actor principal: Líder del proyecto.

Caso de uso: Planificar, gestionar y controlar el desarrollo del Pipeline de datos.

Descripción: El líder del proyecto organiza el desarrollo utilizando una metodología ágil, definiendo el Product Backlog, planificando los Sprints y registrando el avance del equipo mediante una herramienta de gestión de proyectos. Durante la ejecución se documentan las actividades realizadas, la infraestructura tecnológica utilizada y las diferencias entre la planificación inicial y la ejecución real.

Flujo general:

1. Se identifican los requerimientos del proyecto.
2. Se construye el Product Backlog.
3. Se planifican los Sprints y el cronograma de trabajo.
4. Se asignan actividades a los integrantes del equipo.
5. Se registra el avance del proyecto en la herramienta de gestión.
6. Se documentan la infraestructura y la gobernanza de TI utilizadas.
7. Se comparan los resultados obtenidos con la planificación inicial.

Resultado esperado: El proyecto se desarrolla de manera organizada, con una planificación documentada, seguimiento continuo y evidencia del cumplimiento de los objetivos establecidos.

Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales

Actor principal: Analista de innovación.

Caso de uso: Evaluar la incorporación de tecnologías emergentes dentro de una solución basada en datos.

Descripción: El analista estudia cómo la integración de Big Data, Machine Learning y servicios en la nube aporta valor al modelo de negocio, identificando oportunidades de innovación, ventajas competitivas y procesos de transformación digital que puedan beneficiar a la organización.

Flujo general:

1. Se identifica el problema de negocio.
2. Se analizan las tecnologías emergentes aplicables.
3. Se evalúa el modelo de negocio asociado a la solución.
4. Se identifican oportunidades de innovación.
5. Se documentan los beneficios obtenidos mediante la solución tecnológica.
6. Se presentan recomendaciones para fortalecer la transformación digital.

Resultado esperado:

La solución tecnológica incorpora tecnologías emergentes justificadas técnicamente y alineadas con un modelo de negocio digital que aporta valor a la organización.

Prácticas y Herramientas de Big Data

Actor principal: Ingeniero de datos.

Caso de uso: Extraer, procesar y preparar grandes volúmenes de datos para su análisis.

Descripción: El ingeniero de datos implementa un proceso ETL utilizando Google Colab, consumiendo información desde una API abierta, realizando procesos de limpieza, transformación e integración de datos para generar un conjunto de información preparado para el entrenamiento de modelos de Machine Learning.

Flujo general:

1. Se establece la conexión con una API.
2. Se extraen los datos requeridos.
3. Se realiza la limpieza y transformación de la información.
4. Se integran los conjuntos de datos necesarios.
5. Se almacenan los datos procesados.
6. Se ejecutan pruebas utilizando diferentes alternativas de procesamiento.
7. Se valida la calidad de los datos obtenidos.

Resultado esperado: El pipeline genera datos limpios, estructurados y preparados para ser utilizados por los modelos de aprendizaje automático.

Machine Learning

Actor principal: Científico de datos.

Caso de uso: Entrenar y evaluar modelos de Machine Learning para apoyar la toma de decisiones.

Descripción:

El científico de datos utiliza el conjunto de datos generado durante el procesamiento para entrenar diferentes modelos de aprendizaje automático, comparar su desempeño mediante métricas de evaluación y seleccionar el modelo con mejores resultados, presentando los hallazgos mediante dashboards y visualizaciones.

Flujo general:

1. Se cargan los datos procesados.
2. Se preparan las variables de entrenamiento y prueba.
3. Se entrenan diferentes modelos de Machine Learning.
4. Se calculan las métricas de desempeño.
5. Se comparan los resultados obtenidos.
6. Se selecciona el modelo con mejor rendimiento.
7. Se generan dashboards y visualizaciones de resultados.
8. Se documenta la justificación técnica de la solución seleccionada.

Resultado esperado:

Se obtiene un modelo predictivo validado, respaldado por métricas objetivas y visualizaciones que facilitan la interpretación de los resultados.

Ciberseguridad

Actor principal: Analista de ciberseguridad.

Caso de uso: Identificar vulnerabilidades y proponer mecanismos de protección para el intercambio seguro de datos.

Descripción:

El analista de ciberseguridad evalúa las APIs consumidas, las herramientas de conexión y la infraestructura tecnológica utilizada durante el proyecto, identificando posibles amenazas y proponiendo controles orientados a proteger la información durante su procesamiento e intercambio.

Flujo general:

1. Se identifican las APIs y servicios utilizados.
2. Se analizan posibles vulnerabilidades.
3. Se evalúan riesgos relacionados con autenticación, autorización y exposición de datos.
4. Se analiza la seguridad de la infraestructura tecnológica.
5. Se proponen mecanismos de mitigación.
6. Se verifica el cumplimiento de la confidencialidad, integridad y disponibilidad de la información.
7. Se documentan los hallazgos y recomendaciones de seguridad.

Resultado esperado:

El proyecto incorpora un análisis de seguridad que identifica riesgos, propone mecanismos de mitigación y fortalece la protección de los datos durante todo el pipeline de datos.

Diseño de arquitectura



Desarrollo

En esta sección se describirá el proceso de implementación del Pipeline de datos, detallando las tecnologías utilizadas, la organización del proyecto y el desarrollo de las funcionalidades implementadas en cada una de las asignaturas participantes.

Tecnologías

En esta sección deberán describirse las tecnologías, herramientas y plataformas utilizadas durante el desarrollo del proyecto, justificando su selección de acuerdo con los requerimientos técnicos de la solución implementada.

Estructura del proyecto

En esta sección deberá describirse cómo se organizó el Pipeline de datos, explicando la distribución de los diferentes componentes, la interacción entre las etapas de procesamiento y la integración de las tecnologías utilizadas durante el desarrollo.

1. Desarrollo de Proyectos de Sistemas de Información
    - Organización del proyecto.
    - Product Backlog.
    - Planificación de Sprints.
    - Cronograma de desarrollo.
    - Herramienta de gestión utilizada (Jira, Trello, Azure DevOps o similar).
    - Gestión de tareas y seguimiento del proyecto.
    - Gestión y gobernanza de la infraestructura de TI.
    - Organización del repositorio Git.
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales
    - Identificación de tecnologías emergentes utilizadas.
    - Justificación tecnológica de la solución.
    - Modelo de negocio propuesto.
    - Arquitectura orientada a datos.
    - Estrategia de transformación digital.
    - Propuesta de valor de la solución.
    - Beneficios tecnológicos y organizacionales.
3. Prácticas y Herramientas de Big Data
    - Arquitectura del Pipeline de Datos.
    - Fuente de datos (APIs utilizadas).
    - Flujo ETL (Extracción, Transformación y Carga).
    - Proceso de limpieza y transformación de datos.
    - Integración de múltiples fuentes de información (si aplica).
    - Organización del procesamiento en Google Colab.
    - Comparación entre los modelos de procesamiento implementados.
    - Diagrama del flujo de datos.
4. Machine Learning
    - Arquitectura del modelo predictivo.
    - Preparación del conjunto de datos.
    - Ingeniería de características.
    - Modelos implementados.
    - Comparación entre algoritmos.
    - Métricas de evaluación.

- Dashboards y visualizaciones.
- Justificación técnica del modelo seleccionado.

5. Ciberseguridad

- Arquitectura de seguridad del proyecto.
- Análisis de las APIs consumidas.
- Evaluación de vulnerabilidades.
- Riesgos identificados.
- Controles de seguridad implementados.
- Estrategias de mitigación.
- Protección de la información durante el intercambio de datos.
- Aplicación de la tríada CIA (Confidencialidad, Integridad y Disponibilidad).

Desarrollo de funcionalidades

1. Desarrollo de Proyectos de Sistemas de Información

Se deberá documentar la planificación y gestión del proyecto:

- Objetivo.
- Descripción.
- Product Backlog.
- Sprint correspondiente.
- Evidencia de planificación.
- Evidencia del seguimiento realizado.
- Comparación entre planificación y ejecución.
- Evidencia de la herramienta de gestión utilizada.

2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales

Se deberá documentar el análisis tecnológico realizado.

- Problema de negocio identificado.
- Tecnologías emergentes seleccionadas.
- Justificación de la solución tecnológica.
- Modelo de negocio propuesto.
- Beneficios esperados.
- Impacto en la transformación digital.
- Evidencias del análisis realizado.

3. Prácticas y Herramientas de Big Data

Se deberá documentar el desarrollo del Pipeline de Datos.

- Conexión a la API.
- Extracción de datos.
- Proceso ETL.
- Limpieza de datos.
- Transformación de información.
- Integración de datasets (si aplica).
- Comparación entre los modelos de procesamiento.
- Evidencias del procesamiento realizado.

4. Machine Learning

Se deberá documentar el desarrollo del modelo predictivo.

- Preparación del dataset.
- División de datos para entrenamiento y prueba.
- Modelos implementados.
- Entrenamiento de modelos.
- Comparación de métricas.
- Selección del modelo final.
- Dashboards y visualizaciones.
- Evidencias de funcionamiento.

5. Ciberseguridad

Se deberá documentar el análisis de seguridad realizado.

- APIs evaluadas.
- Herramientas utilizadas para el análisis.
- Vulnerabilidades identificadas.
- Riesgos encontrados.
- Evaluación de la infraestructura tecnológica.
- Controles de seguridad propuestos.
- Estrategias de mitigación implementadas.
- Evidencias del análisis de seguridad.

Resultados

Esta sección debe evidenciar que la solución fue validada, no solo implementada. Los resultados deberán demostrar el correcto funcionamiento del Pipeline de datos, validando la planificación del proyecto, el procesamiento de datos, el desempeño de los modelos de Machine Learning, el análisis de tecnologías emergentes y la evaluación de la seguridad de las APIs e infraestructura tecnológica. La evidencia deberá presentarse organizada por asignatura y concluir con una validación integral del proyecto.

Casos de prueba

En esta sección se presentarán las evidencias obtenidas durante la implementación y validación de la solución propuesta. Los resultados deberán demostrar el correcto funcionamiento del pipeline de datos, la gestión del proyecto, los modelos predictivos, el análisis tecnológico y los mecanismos de seguridad implementados.

1. Desarrollo de proyectos de sistemas de información
2. Tendencias en tecnologías emergentes y modelos de negocios digitales
3. Prácticas y herramientas de Big Data
4. Machine Learning
5. Ciberseguridad

Resultados de funcionalidades

En esta sección se presentarán los resultados obtenidos durante la implementación del proyecto, demostrando el cumplimiento de los requerimientos funcionales definidos para cada asignatura.

1. Desarrollo de Proyectos de Sistemas de Información
   - Product Backlog implementado.
   - Cronograma del proyecto.
   - Planificación y ejecución de los Sprints.
   - Seguimiento del avance del proyecto.
   - Comparación entre planificación y ejecución.
   - Evidencias de la herramienta de gestión utilizada.
   - Documentación de la gobernanza e infraestructura de TI.

2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales
    - Tecnologías emergentes implementadas.
    - Modelo de negocio propuesto.
    - Justificación tecnológica de la solución.
    - Estrategia de transformación digital.
    - Beneficios competitivos identificados.
    - Recomendaciones para futuras mejoras.
3. Prácticas y Herramientas de Big Data
    - Conexión a las APIs.
    - Datos obtenidos durante la extracción.
    - Resultados del proceso ETL.
    - Dataset procesado.
    - Comparación de los modelos de procesamiento.
    - Flujo completo del Pipeline de Datos.
    - Validación de la calidad de la información.
4. Machine Learning
    - Preparación del conjunto de datos.
    - Modelos implementados.
    - Resultados del entrenamiento.
    - Comparación de métricas.
    - Modelo seleccionado.
    - Dashboards generados.
    - Predicciones obtenidas.
    - Justificación técnica de la solución implementada.
5. Ciberseguridad
    - Resultados del análisis de vulnerabilidades.
    - Evaluación de la seguridad de las APIs.
    - Riesgos identificados.
    - Estrategias de mitigación propuestas.
    - Aplicación de la tríada de seguridad (Confidencialidad, Integridad y Disponibilidad).
    - Recomendaciones para fortalecer la seguridad del ecosistema tecnológico.

Capturas de funcionalidades

En esta sección deberán incorporarse las evidencias gráficas que demuestren el funcionamiento del Pipeline de datos implementado. Las capturas deberán estar organizadas por asignatura y acompañadas de una breve descripción.

1. Desarrollo de Proyectos de Sistemas de Información
    - Product Backlog.
    - Tablero Kanban o Scrum.
    - Planificación de Sprints.
    - Cronograma del proyecto.
    - Seguimiento del avance.
    - Herramienta de gestión utilizada.
    - Repositorio Git.
2. Tendencias en Tecnologías Emergentes y Modelos de Negocios Digitales
    - Diagramas de la arquitectura tecnológica.
    - Modelo de negocio propuesto.
    - Propuesta de valor.
    - Diagramas de transformación digital.
    - Evidencias del análisis realizado.
3. Prácticas y Herramientas de Big Data
    - Consumo de la API.
    - Proceso ETL.
    - Limpieza de datos.
    - Transformación de información.
    - Dataset generado.
    - Flujo del Pipeline de Datos.
    - Resultados de los modelos de procesamiento.
4. Machine Learning
    - Preparación del dataset.
    - Entrenamiento de modelos.
    - Comparación de métricas.
    - Matrices de evaluación.
    - Dashboards.

- Visualizaciones.
- Resultados del modelo predictivo.

5. Ciberseguridad
    - Herramientas utilizadas para el análisis de seguridad.
    - Evidencias del análisis de vulnerabilidades.
    - Resultados de las evaluaciones realizadas.
    - Riesgos identificados.
    - Estrategias de mitigación.
    - Diagramas de la arquitectura de seguridad.
    - Evidencias del cumplimiento de la tríada CIA

Rúbricas de calificación

1. Desarrollo de proyectos de sistemas de información

Criterio	4	3	2	1	0
Planificación y gestión ágil del proyecto	Presenta Product Backlog completo, historias de usuario bien definidas, planificación de Sprints coherente, cronograma detallado y gestión continua mediante una herramienta ágil con evidencias de seguimiento.	Presenta todos los elementos de planificación, aunque existen pequeñas inconsistencias o el seguimiento no es completamente continuo.	La planificación es parcial; faltan historias de usuario, Sprints o el cronograma presenta deficiencias importantes.	Existe una planificación mínima, poco estructurada y sin evidencias suficientes de gestión.	No presenta planificación del proyecto.
Ejecución, seguimiento y control	Evidencia el desarrollo mediante registros periódicos, compara planificación vs. ejecución, analiza desviaciones y propone acciones de mejora fundamentadas.	Presenta seguimiento y comparación entre planificación y ejecución con análisis básico.	Existe seguimiento limitado o incompleto y la comparación es superficial.	Solo presenta evidencias aisladas del avance sin análisis.	No evidencia seguimiento del proyecto.
Gestión de infraestructura, gobernanza y repositorio	Documenta claramente la infraestructura, gobernanza de TI y mantiene un	Documenta infraestructura y repositorio con pequeños vacíos de	La documentación es parcial y el repositorio presenta	Presenta únicamente algunos elementos sin	No documenta infraestructura, gobernanza ni repositorio.

	repositorio Git organizado, con historial consistente y buenas prácticas.	organización o detalle.	problemas de organización.	evidencia suficiente.	
Documentación técnica y presentación	La documentación es completa, estructurada, coherente y respalda todas las decisiones tomadas mediante evidencias claras.	La documentación es adecuada con ligeras omisiones o problemas de organización.	La documentación presenta información incompleta y limitada justificación técnica.	La documentación es deficiente y dificulta comprender el proyecto.	No entrega documentación.

2. Tendencias en tecnologías emergentes y modelos de negocios digitales

Criterio	**4**	**3**	**2**	**1**	**0**
Análisis de tecnologías emergentes	Identifica y justifica técnicamente tecnologías emergentes totalmente alineadas con la problemática y la solución desarrollada.	Identifica tecnologías pertinentes con justificación suficiente.	El análisis es limitado y la justificación es parcial.	Solo menciona tecnologías sin análisis relevante.	No presenta análisis tecnológico.
Modelo de negocio y propuesta de valor	Desarrolla un modelo de negocio sólido, identifica claramente la propuesta de valor y demuestra ventajas competitivas sustentadas.	Presenta un modelo de negocio adecuado con propuesta de valor parcialmente desarrollada.	El modelo de negocio presenta debilidades conceptuales o poca relación con la solución.	El modelo es superficial y poco fundamentado.	No presenta modelo de negocio.
Transformación digital e innovación	Analiza profundamente el impacto de la transformación digital e identifica oportunidades reales de innovación sustentadas.	Analiza adecuadamente la transformación digital con algunas oportunidades de innovación.	El análisis es limitado y poco profundo.	Solo describe conceptos generales sin aplicarlos al proyecto.	No desarrolla este aspecto.

Fundamentación y documentación	Presenta evidencia, referencias y documentación técnica organizada que respalda todas las conclusiones.	Presenta documentación suficiente con pequeñas omisiones.	La documentación es incompleta y con escaso sustento técnico.	Presenta documentación mínima.	No presenta documentación.

3. Prácticas y herramientas de Big Data

Criterio	4	3	2	1	0
Implementación del Pipeline ETL	Implementa correctamente todo el pipeline de extracción, transformación y carga desde APIs utilizando Google Colab, documentando cada etapa.	Implementa el pipeline completo con pequeñas deficiencias técnicas o de documentación.	El pipeline funciona parcialmente o presenta etapas incompletas.	Implementa únicamente algunas fases del proceso ETL.	No implementa el pipeline.
Preparación y calidad de los datos	Realiza limpieza, transformación e integración de datos garantizando calidad, consistencia e integridad mediante validaciones.	Ejecuta adecuadamente la preparación de datos con pocas validaciones.	La limpieza y transformación son limitadas o presentan errores importantes.	La preparación de datos es mínima e insuficiente.	No realiza preparación de datos.
Procesamiento y comparación de alternativas	Implementa y compara al menos tres alternativas de procesamiento mediante métricas y análisis técnico claramente justificados.	Compara las alternativas con análisis suficiente.	Presenta comparación limitada o poco fundamentada.	Implementa una única alternativa o la comparación carece de sustento.	No realiza comparación.
Documentación y organización del pipeline	Documenta completamente el flujo de datos mediante diagramas, evidencias y explicación técnica clara del procesamiento.	Documenta adecuadamente el pipeline con pequeños vacíos.	La documentación es parcial y dificulta comprender el flujo.	Presenta escasa documentación.	No documenta el pipeline.

4. Machine Learning

Criterio	4	3	2	1	0
Preparación del conjunto de datos	Realiza preparación completa del dataset, ingeniería de características y división adecuada de entrenamiento y prueba con justificación técnica.	Prepara correctamente el conjunto de datos con ligeras deficiencias.	La preparación presenta limitaciones importantes o escasa justificación.	La preparación es mínima y afecta el desarrollo del modelo.	No prepara los datos.
Desarrollo y comparación de modelos	Implementa al menos tres modelos, compara rigurosamente su desempeño mediante métricas apropiadas y selecciona el mejor con fundamento técnico.	Implementa varios modelos con comparación adecuada.	Presenta pocos modelos o comparación superficial.	Implementa un único modelo o sin análisis comparativo.	No desarrolla modelos.
Evaluación y visualización de resultados	Presenta métricas, dashboards y visualizaciones claras que permiten interpretar correctamente el desempeño del modelo.	Presenta métricas y visualizaciones suficientes.	Presenta resultados limitados o difíciles de interpretar.	Incluye únicamente resultados básicos sin análisis.	No presenta resultados.
Justificación técnica y documentación	Justifica técnicamente algoritmos, parámetros y herramientas empleadas mediante documentación clara y completa.	Justifica la mayoría de decisiones técnicas.	La justificación es parcial o insuficiente.	Presenta escasa fundamentación técnica.	No presenta documentación.

5. Ciberseguridad

Criterio	4	3	2	1	0
Análisis de vulnerabilidades y riesgos	Identifica de forma exhaustiva vulnerabilidades de APIs, infraestructura y comunicaciones, evaluando adecuadamente los riesgos asociados.	Identifica la mayoría de vulnerabilidades relevantes con análisis suficiente.	El análisis es parcial y omite riesgos importantes.	Identifica pocas vulnerabilidades sin evaluación adecuada.	No realiza análisis de seguridad.
Controles y estrategias de mitigación	Propone e implementa controles de seguridad pertinentes, técnicamente viables y alineados con los riesgos identificados.	Propone controles adecuados con implementación parcial.	Presenta estrategias generales con escasa aplicabilidad.	Propone recomendaciones superficiales.	No propone mecanismos de mitigación.
Aplicación de principios de seguridad	Evalúa y demuestra claramente la confidencialidad, integridad y disponibilidad de la información durante todo el pipeline.	Aplica correctamente la mayoría de principios de seguridad.	Considera parcialmente la tríada CIA.	Menciona conceptos sin evidencias de aplicación.	No considera principios de seguridad.
Documentación y evidencias	Presenta un informe técnico completo con evidencias, herramientas utilizadas, resultados, recomendaciones y conclusiones bien fundamentadas.	Presenta documentación adecuada con pequeñas omisiones.	La documentación es parcial y limitada.	Presenta evidencia insuficiente.	No entrega documentación.

Conclusiones

En esta sección, el grupo deberá presentar una reflexión sobre los resultados obtenidos durante el desarrollo del proyecto, evaluando el cumplimiento de los objetivos planteados y la integración de las diferentes asignaturas.